



PROJET DE FIN D'ANNEE

4^{ème} Année
Informatique Industrielle et Automatique

FacturoBot

Système intelligent de génération et de détection de conformité des factures assisté par l'IA

Présenté par
Boukhchina Rayen Ayedi
Chaabouni Safa

Soutenu le mardi 10 juin 2025 devant le Jury composé de

Mme Boubaker Olfa
en sa qualité d'examinatrice

Dr Ben Ali Khaoula
en sa qualité d'encadrante

Année Universitaire 2025 – 2026

Remerciements

Nous tenons à exprimer notre profonde gratitude à toutes les personnes qui ont contribué à la réalisation de notre projet de fin d'études, FacturoBot : Système intelligent de génération et de détection de conformité des factures assisté par l'IA.

Nos remerciements les plus sincères vont en premier lieu à notre encadrante, **Dr Ben Ali Khaoula**, pour ses précieux conseils, ses retours constructifs et son soutien constant tout au long de ce projet. Son expertise et ses orientations ont été déterminantes dans la concrétisation de ce travail.

Nous remercions également nos professeurs de l'Institut national des sciences appliquées et de technologie pour nous avoir transmis les connaissances et compétences nécessaires à la réalisation de ce projet. Une mention spéciale à **Professeure Boubaker Olfa** pour avoir accepté de faire partie du jury d'évaluation.

Nous tenons également à remercier la Junior Entreprise INSAT, dont l'environnement stimulant et les expériences concrètes de gestion ont été une véritable source d'inspiration dans le choix et la conception de notre projet.

À nos collègues et amis, merci pour votre motivation et les échanges techniques qui ont permis d'enrichir ce projet.

Enfin, nous exprimons notre gratitude la plus profonde à nos familles pour leur soutien indéfectible.

Tunis, 10 Juin 2025.

Table des matières

Introduction Générale	1
1 Cadre du projet	2
1.1 Étude de l'existant	3
1.1.1 État de l'art en gestion de la facturation	3
1.1.2 Limitations des systèmes actuels	3
1.1.3 Enjeux réglementaires et de conformité	4
1.2 Problématique	4
1.2.1 Contexte et enjeux	4
1.2.2 Question de recherche	5
1.3 Solution proposée	6
1.3.1 Vue d'ensemble	6
1.3.2 Utilisateurs cibles	6
1.3.3 Étude des concepts et approches	6
1.4 Analyse des besoins	7
1.4.1 Besoins fonctionnels	7
1.4.2 Besoins non fonctionnels	7
2 Architecture Technique du Système	9
2.1 Architecture Globale	10
2.1.1 Vue d'Ensemble	10
2.1.2 Flux de Données	11
2.2 Technologies et Outils Utilisés	14
2.2.1 Environnement de Développement	14
2.2.2 Frameworks et Bibliothèques	14
2.3 Concepts Clés	16
2.3.1 Modèles de Langage de Grande Taille (LLMs)	16
2.3.2 Web Scraping	16

3	Conception et Implémentation du Module de Génération de Factures	18
3.1	Conception Détaillée	19
3.1.1	Évolution de la Conception : Du Statique au Conversationnel	19
3.1.2	Architecture du Module de Génération Actuel	19
3.2	Implémentation	20
3.2.1	Chatbot et Interaction LLM	20
3.2.2	Génération PDF	21
3.2.3	Interface Web (Flask)	21
3.3	Structuration des Données	22
3.4	Réalisations et Visualisations	22
3.5	Défis et Améliorations Futures	24
4	Conception et Implémentation du Module d'Extraction de Factures	25
4.1	Conception Détaillée	26
4.1.1	Vue d'Ensemble du Pipeline d'Extraction	26
4.2	Implémentation (État Actuel)	26
4.2.1	Conversion PDF vers Image	26
4.2.2	Prétraitement d'Image	27
4.2.3	Détection et Reconnaissance de Texte (OCR)	28
4.2.4	Fusion de Boîtes et Structuration des Données et Enrichissement	29
4.3	Résultats et Visualisations	31
4.4	Défis et Améliorations Futures	34
5	Conception et Implémentation du Module de vérification de conformité des Factures	35
5.1	Conception Détaillée	36
5.1.1	Critères de Vérification des Données	36
5.1.2	Validation Externe : Web Scraping du Matricule Fiscal	37
5.2	Implémentation	38
5.3	Défis et Améliorations Futures	39
6	Conclusion et Perspectives	40
6.1	Évaluation du Projet	41
6.1.1	Réalisations Clés	41

6.1.2	Limites et Défis Rencontrés	41
6.2	Perspectives et Feuille de Route	42
6.2.1	Améliorations Techniques	42
6.2.2	Extension Fonctionnelle	43
6.2.3	Considérations Stratégiques	43
6.3	Conclusion	44
	Conclusion Générale	45

Liste des figures

2.1	Architecture Globale de Facturobot	10
2.2	Flux de Données pour la Génération de Factures	12
2.3	Flux de Données pour la Vérification de Conformité	13
3.1	Figures 3.1 et 3.2 : Interface Web du Chatbot et Aperçu de la Facture	23
3.2	Figures 3.3 et 3.4 : Exemple de Facture Générée et Historique des Factures	23
3.3	Figure 3.5 : Structure du Fichier factures.csv	23
4.1	Exemple de Correction de Perspective	31
4.2	Facture Originale en Entrée	31
4.3	Détection des Lignes Horizontales (Y-Facture)	32
4.4	Détection des Lignes Verticales (X-Facture)	32
4.5	Facture après Suppression des Lignes	33
4.6	Extrait des Données Structurées	33

Introduction Générale

Dans un monde professionnel de plus en plus digitalisé, la gestion documentaire représente un pilier fondamental de la performance administrative et financière des organisations. Parmi les documents les plus critiques figure la facture, qui constitue à la fois une preuve de transaction, un support juridique et un élément clé dans le suivi de la trésorerie.

Cependant, de nombreuses structures — qu’il s’agisse d’associations, de startups ou de petites entreprises — continuent de traiter les factures de manière manuelle, s’exposant ainsi à des erreurs humaines, des pertes de temps et des risques de non-conformité réglementaire. C’est dans ce contexte que le projet FacturoBot a vu le jour : un assistant intelligent capable d’automatiser à la fois la génération et la vérification de factures.

Ce projet a été développé au sein de la Junior Entreprise INSAT, à partir d’un besoin réel identifié par ses membres. Il vise à offrir une solution innovante basée sur les technologies d’intelligence artificielle, les modèles de langage (LLMs) et les systèmes d’extraction de données, afin d’optimiser les processus liés à la facturation.

La présente étude s’articule autour de plusieurs axes : l’analyse du besoin, la conception du système, la mise en œuvre technique (génération et extraction), ainsi que l’évaluation de sa performance et de sa robustesse. Le système FacturoBot intègre des modules de compréhension du langage naturel (pour dialoguer avec l’utilisateur), de génération automatique de documents, d’OCR pour l’extraction de données depuis des fichiers reçus, et de vérification des données à travers des règles métier et des vérifications externes (notamment via le site du Registre National des Entreprises tunisien).

Ce projet s’inscrit pleinement dans la dynamique actuelle de transformation numérique des fonctions administratives et financières. Il constitue une contribution concrète à l’application de l’intelligence artificielle au service de la gestion documentaire, et plus largement, à la modernisation des pratiques de travail au sein des organisations.

CADRE DU PROJET

1.1 Étude de l'existant

1.1.1 État de l'art en gestion de la facturation

La gestion des documents comptables, en particulier les factures, représente un enjeu central pour les organisations de toutes tailles, qu'il s'agisse d'associations, de startups, de PME ou même d'entreprises plus établies. Bien que leurs contextes organisationnels diffèrent, ces structures font face à des défis communs en matière de production, de validation, d'archivage et de conformité des documents financiers.

Dans de nombreuses structures, la génération des factures repose encore sur des processus manuels, réalisés à l'aide de logiciels bureautiques classiques (comme Microsoft Word ou Excel). Cette approche, bien que simple à mettre en œuvre, présente de nombreuses limites :

- Temps de traitement élevé et charge administrative importante.
- Manque de standardisation dans les formats de factures.
- Risque accru d'erreurs humaines (saisie erronée, oublis, incohérences).
- Difficulté à garantir la traçabilité et la conformité réglementaire.

Face à ces constats, l'automatisation de la facturation devient une nécessité. L'émergence des technologies d'intelligence artificielle, notamment les modèles de langage de grande taille (LLMs), offre aujourd'hui une opportunité concrète pour transformer ces processus. Les LLMs [1],[2],[3] sont capables de comprendre des instructions en langage naturel ou vocal, d'en extraire les informations pertinentes, puis de générer automatiquement des contenus structurés, tels que des factures ou devis. Malgré ce potentiel, l'adoption de ces solutions reste encore limitée, notamment en contexte tunisien, où peu d'initiatives ont été concrétisées à l'échelle locale ou associative.

1.1.2 Limitations des systèmes actuels

Les solutions actuellement utilisées présentent de nombreuses failles, aussi bien sur le plan technique que réglementaire. Parmi les principales limitations identifiées :

- **Absence d'automatisation** : la majorité des outils utilisés ne permettent pas une génération dynamique ou automatisée des factures.
- **Risques d'erreurs** : la dépendance aux opérations manuelles (copier-coller, remplissage de champs) rend les documents vulnérables aux fautes de saisie, aux oublis et aux incohérences.

- **Conformité non garantie** : les systèmes ne permettent pas de vérifier automatiquement si une facture est conforme aux exigences fiscales et réglementaires, notamment en ce qui concerne les mentions obligatoires (identité du fournisseur, numéro de patente, numérotation, etc.).
- **Traçabilité faible** : la vérification de l'historique des modifications ou des validations est souvent inexistante ou insuffisamment structurée.
- **Accessibilité restreinte** : dans certaines structures, les membres n'ont pas toujours une maîtrise des outils ou un accès centralisé aux fichiers comptables.

Ces lacunes peuvent avoir des conséquences graves, notamment lors d'un audit, d'un contrôle fiscal, ou dans le cadre d'un litige avec un client ou un partenaire.

1.1.3 Enjeux réglementaires et de conformité

La conformité des factures aux normes fiscales et juridiques en vigueur est une exigence fondamentale, aussi bien pour les entreprises que pour les associations. En Tunisie, toute facture émise ou reçue doit comporter un ensemble de mentions obligatoires clairement définies par la législation. Parmi ces mentions, on retrouve notamment :

- Le numéro de la facture et sa date d'émission.
- Les informations précises sur le fournisseur (nom, adresse, matricule fiscal ou numéro de patente).
- Les coordonnées du client.
- Le détail des prestations fournies ou des biens livrés.
- Le montant HT, la TVA, et le montant TTC.

Tout manquement ou erreur peut exposer l'organisation à des sanctions administratives, à des litiges juridiques ou à des redressements lors d'un contrôle. Pour les associations telles que la Junior Entreprise INSAT (JEI), qui gèrent un volume croissant de prestations et sont régulièrement soumises à des audits, ces enjeux de conformité prennent une dimension critique.

1.2 Problématique

1.2.1 Contexte et enjeux

Dans le cadre de nos activités au sein de la Junior Entreprise INSAT, nous avons constaté des difficultés récurrentes liées à la gestion des factures : création lente, erreurs fréquentes, retours

des clients en raison d'informations manquantes, et difficulté à suivre les obligations légales. Ces observations ont été renforcées par l'expérience directe de l'un des membres du projet, en tant que président de la JEI.

Au-delà du contexte associatif, ce constat s'applique également aux petites structures entrepreneuriales ou startups qui ne disposent pas de systèmes comptables avancés. Le besoin d'un outil simple, intelligent et conforme à la législation est donc généralisé.

Les principaux enjeux identifiés sont :

- Réduire le temps et les efforts consacrés à la génération des factures.
- Diminuer les erreurs humaines liées à la saisie manuelle.
- Garantir automatiquement la conformité des factures selon les normes tunisiennes.
- Faciliter l'audit, le suivi et l'archivage des documents comptables.

1.2.2 Question de recherche

Face à ces besoins, la question centrale de notre projet peut être formulée ainsi :

Comment concevoir un système intelligent, simple d'utilisation, capable de générer automatiquement des factures à partir d'un prompt textuel ou vocal, tout en assurant leur conformité légale et leur traçabilité ?

Cette question soulève plusieurs sous-enjeux :

- Quelles informations doivent être extraites d'un prompt en langage naturel pour générer une facture complète ?
- Comment structurer un système capable de détecter les champs manquants ou erronés avant la génération ?
- Comment automatiser la vérification de conformité à partir d'un document facture reçu (PDF, image) ?
- Comment intégrer un système de dialogue interactif (chatbot) pour rendre cette technologie accessible aux non-spécialistes ?

1.3 Solution proposée

1.3.1 Vue d'ensemble

Pour répondre à cette problématique, nous avons conçu **FacturoBot** : un système intelligent de génération et de vérification de factures basé sur l'intelligence artificielle.

Ce système se compose de deux modules principaux :

- **Génération assistée de factures** : un chatbot basé sur un modèle de langage (LLM), capable de comprendre des requêtes en langage naturel ou vocal, d'en extraire les informations pertinentes (produits, client, prix, etc.) et de générer automatiquement une facture complète au format PDF.
- **Vérification de conformité** : un module capable de recevoir une facture en entrée (au format PDF ou image), d'en extraire les données via OCR[4], puis d'appliquer un ensemble de règles pour détecter toute anomalie ou non-conformité par rapport à la législation tunisienne.

L'ensemble du système vise à réduire la charge de travail, minimiser les erreurs humaines et garantir un haut niveau de conformité.

1.3.2 Utilisateurs cibles

- Les membres de la Junior Entreprise INSAT (trésorier, chef de projet, président...).
- Les responsables administratifs et financiers de petites associations ou clubs étudiants.
- Les startups et petites entreprises cherchant à automatiser leur facturation.
- Éventuellement, toute structure soumise à des obligations de facturation et disposant de ressources limitées.

1.3.3 Étude des concepts et approches

Notre approche repose sur l'intégration de plusieurs concepts technologiques complémentaires :

- **Modèles de langage (LLMs)** : Ces modèles permettent de comprendre des requêtes en langage naturel et d'en extraire des éléments structurés. Nous avons utilisé Gemini Pro (via l'API de Google) pour la génération des factures, avec une adaptation au contexte tunisien.
- **Prompt engineering** : L'efficacité de la génération repose sur la qualité du prompt envoyé au LLM. Nous avons conçu un prompt standardisé, intégrant les règles de facturation.

- **OCR & parsing de documents** : Le module de conformité s'appuie sur l'OCR pour extraire les données d'une facture au format image ou PDF (utilisation de `pytesseract`, `pdfplumber`...).
- **Vérification par règles** : Une couche de règles conditionnelles permet d'évaluer la validité de chaque champ (date, numéro de facture, N° de patente, TVA, etc.).
- **Génération de PDF** : Nous utilisons des templates HTML/CSS convertis en PDF à l'aide d'une librairie comme `WeasyPrint` ou `FPDF`, permettant une personnalisation du design.
- **Persistance** : Les données extraites ou générées sont enregistrées dans un fichier CSV ou une base légère, afin d'assurer la traçabilité.

Cette combinaison d'approches permet de couvrir à la fois la génération proactive des documents et le contrôle a posteriori des factures existantes.

1.4 Analyse des besoins

1.4.1 Besoins fonctionnels

Les besoins fonctionnels du système FacturoBot sont les suivants :

- L'utilisateur doit pouvoir initier une conversation (texte ou vocale) avec le chatbot pour demander la génération d'une facture.
- Le système doit extraire automatiquement les informations nécessaires à partir du prompt.
- Le système doit détecter les informations manquantes et en informer l'utilisateur.
- Le système doit générer une facture conforme au format standard PDF.
- L'utilisateur doit pouvoir télécharger la facture générée.
- Le système doit permettre de soumettre une facture existante (PDF/image) pour contrôle.
- Le système doit extraire les champs d'une facture (montant, fournisseur, client, date...).
- Le système doit vérifier la conformité de ces champs selon des règles définies.
- Le système doit notifier l'utilisateur en cas d'erreurs ou d'incohérences détectées.
- Un administrateur doit pouvoir mettre à jour ou ajouter des règles de conformité.

1.4.2 Besoins non fonctionnels

En plus des fonctionnalités, plusieurs contraintes techniques et qualités logicielles doivent être respectées :

- **Accessibilité** : L'interface doit être intuitive, utilisable sans compétences techniques.
- **Rapidité** : Le temps de génération ou de vérification d'une facture doit être inférieur à 5 secondes dans la majorité des cas.
- **Fiabilité** : Les données extraites ou générées doivent être correctes à plus de 95 %.
- **Conformité** : Le système doit intégrer les règles fiscales tunisiennes.
- **Sécurité** : Les données personnelles (nom, facture, montant) doivent être traitées de manière confidentielle.
- **Traçabilité** : Chaque action (génération, modification, téléchargement) doit être journalisée.
- **Portabilité** : Le système doit être déployable localement ou dans le cloud.
- **Maintenabilité** : L'ajout de nouvelles règles ou de nouveaux formats doit être simple à implémenter.

ARCHITECTURE TECHNIQUE DU SYSTÈME

2.1 Architecture Globale

2.1.1 Vue d'Ensemble

Le système Facturobot est conçu comme une application web modulaire, articulée autour de deux fonctionnalités principales : la génération assistée de factures et la vérification de conformité des factures existantes. Cette architecture permet une interaction fluide avec l'utilisateur tout en exploitant des technologies d'intelligence artificielle pour automatiser des tâches complexes.




FIGURE 2.1 : Architecture Globale de Facturobot

Au cœur du système se trouve une **Application Web** développée avec le framework Flask, servant d'interface utilisateur principale. Cette application est divisée en deux sections majeures : une dédiée à la **Génération de Factures** via un chatbot, et une autre pour la **Vérification de Conformité** des factures existantes. Les utilisateurs peuvent interagir avec le système via un **Chatbot** qui prend en charge les entrées textuelles et vocales. Ce chatbot est alimenté par un **Modèle de Langage de Grande Taille (LLM)**, spécifiquement Gemini Pro de Google, qui est responsable de la compréhension du langage naturel et de l'extraction des informations pertinentes pour la facturation.

Le processus de génération de factures implique le **Module de Génération de Factures** qui, à partir des données structurées fournies par le LLM, crée des documents PDF conformes. Ces factures générées sont ensuite stockées dans une **Base de Données/CSV** pour assurer la

persistance et la traçabilité.

Parallèlement, le système intègre un **Module de Vérification de Conformité** des factures. Ce module accepte des factures sous format PDF ou image. Un **Module OCR (Optical Character Recognition)**, développé via un algorithme spécifique et non une bibliothèque OCR prête à l'emploi, est utilisé pour extraire le texte et les données de ces documents. Les informations extraites sont ensuite traitées par un **Module de Règles** qui applique un ensemble de critères prédéfinis pour détecter les anomalies et vérifier la conformité de la facture. Les résultats de cette vérification sont également gérés et potentiellement stockés dans la Base de Données/CSV. Le module de vérification de conformité est une section distincte de l'application web et n'est pas directement lié au chatbot de génération.

Cette architecture modulaire assure une bonne séparation des préoccupations, facilitant ainsi la maintenance, l'évolutivité et l'intégration de nouvelles fonctionnalités ou technologies à l'avenir.

2.1.2 Flux de Données

Les flux de données au sein de Facturobot sont distincts pour les deux fonctionnalités principales : la génération de factures et la vérification de conformité.

Flux de Données pour la Génération de Factures

Le processus de génération de factures débute par l'interaction de l'utilisateur avec le système. La figure 2.2 illustre ce flux de données.




FIGURE 2.2 : Flux de Données pour la Génération de Factures

- **Interaction Utilisateur-Chatbot** : L'utilisateur fournit au chatbot une description de la facture désirée, soit par texte, soit par voix. Le chatbot répond en demandant des informations complémentaires si certains détails sont manquants.
- **Chatbot-LLM** : Le Chatbot transmet la requête de l'utilisateur au LLM (Gemini). Le LLM analyse la demande, extrait les entités clés (nom du client, produits, quantités, prix, etc.) et structure ces informations au format JSON.
- **Chatbot-Application Web** : Les données structurées sont renvoyées par le LLM au Chatbot, qui les transmet ensuite à l'Application Web, spécifiquement à la section dédiée à la génération de factures.
- **Application Web-Module de Génération de Factures** : L'Application Web utilise ces données pour invoquer le Module de Génération de Factures. Ce module, basé sur des templates HTML/CSS et la bibliothèque `xhtml2pdf`, génère le document PDF de la facture.
- **Module de Génération de Factures-Base de Données/CSV** : La facture générée au format PDF est sauvegardée dans un répertoire dédié, et ses métadonnées (référence, date, client, totaux) sont enregistrées dans un fichier CSV, servant de base de données légère pour l'historique des factures.
- **Base de Données/CSV-Utilisateur** : L'utilisateur peut ensuite télécharger la facture PDF via l'interface de l'Application Web.

Flux de Données pour la Vérification de Conformité

Le processus de vérification de conformité est déclenché lorsqu'une facture existante est soumise au système. La figure 2.3 détaille ce flux.




FIGURE 2.3 : Flux de Données pour la Vérification de Conformité

- **Utilisateur-Application Web** : L'utilisateur télécharge une facture (PDF ou image) via l'interface de l'Application Web, spécifiquement la section dédiée à la vérification de conformité.
- **Module de Vérification de Conformité-Module OCR** : Le Module de Vérification de Conformité envoie le document image au Module OCR. Ce module, développé via un algorithme spécifique, extrait le texte et les champs clés de la facture.
- **Module OCR-Module de Règles** : Les données textuelles et structurées extraites par l'OCR sont transmises au Module de Règles.
- **Module de Règles-Base de Données/CSV** : Le Module de Règles applique un ensemble de règles métier et légales (définies et potentiellement stockées dans la Base de Données/CSV) pour évaluer la conformité de la facture. Il peut également mettre à jour la base de données avec les résultats de la vérification ou les anomalies détectées.
- **Interaction Module de règles - Web scraping** : L'un des critères consiste à vérifier l'existence du Matricule Fiscal du fournisseur, ce qui implique une vérification sur un autre site web via web scraping.

2.2 Technologies et Outils Utilisés

Le développement de Facturobot a nécessité l'utilisation d'un ensemble de technologies et d'outils, choisis pour leur robustesse, leur flexibilité et leur capacité à répondre aux exigences fonctionnelles et non fonctionnelles du projet. Cette section détaille les principaux composants technologiques qui constituent l'épine dorsale du système.

2.2.1 Environnement de Développement

L'environnement de développement a été principalement basé sur **Python**, un langage de programmation polyvalent et largement adopté pour le développement web, l'intelligence artificielle et l'analyse de données. La version de Python utilisée a permis de tirer parti des dernières fonctionnalités et optimisations des bibliothèques. L'écriture, le débogage et la gestion du code ont été facilités par l'utilisation de **Visual Studio Code (VS Code)**, un éditeur de code source léger mais puissant, supportant de nombreuses extensions pour le développement Python.

Pour la gestion des dépendances et des environnements virtuels, des outils standards de l'écosystème Python ont été employés, garantissant ainsi la reproductibilité de l'environnement de développement et la résolution des conflits de versions entre les différentes bibliothèques. Le système est conçu pour être déployable sur des plateformes Linux, ce qui est cohérent avec l'environnement de sandbox utilisé pour le développement et les tests.

2.2.2 Frameworks et Bibliothèques

Facturobot s'appuie sur plusieurs frameworks et bibliothèques clés, chacun jouant un rôle spécifique dans la réalisation des fonctionnalités du système :

- **Flask** : Ce micro-framework web pour Python a été choisi pour construire l'application web principale. Flask offre une grande flexibilité et une structure légère, ce qui est idéal pour développer des applications web modulaires et performantes. Il gère le routage des requêtes HTTP, la gestion des sessions et l'intégration des templates HTML pour l'interface utilisateur.
- **Google Gemini Pro (via API)** : Au cœur de la fonctionnalité de génération de factures, Gemini Pro est le modèle de langage de grande taille (LLM) utilisé pour l'extraction d'informations à partir des requêtes en langage naturel de l'utilisateur. L'intégration via son API permet à Facturobot de bénéficier des capacités avancées de compréhension et de génération de texte de

Gemini, essentielles pour transformer des descriptions informelles en données structurées de facturation.

- **Jinja2** : Utilisé en conjonction avec Flask, Jinja2 est un moteur de templating moderne et rapide pour Python. Il permet de générer dynamiquement le contenu HTML des factures à partir des données extraites par le LLM, offrant une grande flexibilité dans la conception et la personnalisation des modèles de factures.
- **xhtml2pdf (avec ReportLab et html5lib)** : Cette bibliothèque est cruciale pour la conversion des templates HTML générés par Jinja2 en documents PDF. Elle assure la mise en page et le rendu fidèle des factures, garantissant un format professionnel et imprimable. **xhtml2pdf** s'appuie sur ReportLab pour la génération PDF et html5lib pour l'analyse HTML.
- **Pytesseract** : Pour le module de vérification de conformité, Pytesseract sert d'interface Python pour le moteur OCR Tesseract. Il est utilisé pour extraire le texte et les données des factures soumises sous forme d'images ou de PDF, transformant ainsi le contenu visuel en données exploitables.
- **pdf2image** : Cette bibliothèque est utilisée pour convertir les pages des documents PDF en images. Cette étape est nécessaire avant d'appliquer l'OCR avec Pytesseract, car Tesseract fonctionne principalement sur des images.
- **OpenCV (cv2)** : OpenCV est une bibliothèque open-source de vision par ordinateur. Dans Facturobot, elle est utilisée pour le prétraitement des images de factures avant l'OCR. Cela inclut des opérations comme la correction de la perspective (`correctperspectives.py`), la suppression des lignes (`delines.py`), la détection et la fusion des boîtes de texte (`mergeboxes.py`), et la segmentation des colonnes. Ces étapes améliorent considérablement la précision de l'OCR en optimisant la qualité des images d'entrée.
- **Numpy** : Cette bibliothèque est fondamentale pour les opérations numériques et matricielles, en particulier dans les modules de traitement d'image (OpenCV) où elle est utilisée pour manipuler les données d'image de manière efficace.
- **Pandas** : Utilisée pour la manipulation et l'analyse de données, Pandas est une bibliothèque essentielle pour gérer les données structurées, notamment celles extraites des factures ou stockées dans le fichier CSV. Elle facilite les opérations de lecture, écriture et traitement des données tabulaires.

- **CSV (module intégré de Python)** : Pour la persistance des données, notamment l'historique des factures générées et potentiellement les règles de conformité, le module CSV de Python est utilisé. Cela permet une gestion simple et efficace des données structurées sous forme de fichiers plats.

Ces technologies, combinées, forment un écosystème robuste qui permet à Facturobot de remplir ses fonctions de génération et de vérification de factures de manière intelligente et automatisée.

2.3 Concepts Clés

2.3.1 Modèles de Langage de Grande Taille (LLMs)

Les Modèles de Langage de Grande Taille (LLMs) sont des réseaux neuronaux profonds entraînés sur d'énormes corpus de texte, leur permettant de comprendre, générer et manipuler le langage humain. Dans Facturobot, le LLM **Gemini Pro** joue un rôle central dans la fonctionnalité de génération de factures. Il est capable de :

- **Compréhension du Langage Naturel (NLU)** : Interpréter les requêtes complexes des utilisateurs, qu'elles soient textuelles ou vocales, et en extraire les informations pertinentes pour la facturation (nom du client, description des produits, quantités, prix, etc.).
- **Génération de Contenu Structuré** : Transformer les informations extraites en un format structuré (JSON) qui peut être facilement traité par les modules de génération de factures. Cela inclut la capacité de déduire des informations manquantes ou d'effectuer des calculs simples si nécessaire, en se basant sur le contexte de la conversation.

L'utilisation d'un LLM permet à Facturobot d'offrir une interface utilisateur intuitive et conversationnelle, réduisant la nécessité de formulaires rigides et améliorant l'expérience utilisateur en automatisant l'extraction de données [5],[6] à partir d'entrées non structurées.

2.3.2 Web Scraping

Le web scraping est une technique d'extraction automatisée d'informations à partir de sites web. Dans le cadre de notre projet FacturoBot, cette méthode est utilisée pour interroger le site officiel du Registre National des Entreprises (RNE) [7] en Tunisie, dans le but de vérifier automatiquement la validité du matricule fiscal ou du numéro d'identification du fournisseur. Cela permet de garantir que les données présentes sur la facture soient conformes aux informations officielles. Cette approche

est particulièrement utile pour automatiser la collecte de données publiques et fiables, réduisant ainsi les erreurs manuelles et améliorant la précision des vérifications. **Note** : Bien que le terme 'web scraping' soit utilisé ici pour décrire l'extraction de données à partir d'une source web externe (RNE), les techniques d'extraction de données de documents (comme l'OCR pour les factures) partagent des principes similaires d'automatisation de la collecte et de la structuration de l'information.

CONCEPTION ET IMPLÉMENTATION DU MODULE DE GÉNÉRATION DE FACTURES

L'un des piliers centraux du système Facturobot est son module de génération de factures. Initialement conçu comme un outil d'automatisation simple, ce module a évolué pour intégrer des capacités d'intelligence artificielle avancées, offrant une expérience utilisateur intuitive et conversationnelle. Ce chapitre détaille la conception, l'implémentation et l'évolution de ce composant clé.

3.1 Conception Détaillée

3.1.1 Évolution de la Conception : Du Statique au Conversationnel

Au début du projet, l'approche pour la génération de factures était axée sur une automatisation plus traditionnelle. Le fichier `generator.py` représente cette première itération. Il permettait de générer des factures PDF à partir de données structurées fournies manuellement, simulant le remplissage d'un formulaire. Bien que fonctionnel, cette méthode présentait des limites significatives :

- **Manque d'Intelligence Artificielle** : L'outil était purement automatisé et ne tirait pas parti des avancées en IA pour simplifier l'entrée des données.
- **Expérience Utilisateur Répétitive** : Le processus de saisie manuelle des informations pour chaque facture était fastidieux et sujet aux erreurs.
- **Absence d'Innovation** : Cette approche ne répondait pas à l'objectif d'un système intelligent et conversationnel.

Reconnaissant ces lacunes, la conception a pivoté vers une solution plus innovante, intégrant un chatbot alimenté par un Modèle de Langage de Grande Taille (LLM). Cette nouvelle orientation visait à transformer l'interaction utilisateur, passant d'une saisie de formulaire rigide à une conversation naturelle, permettant au système de comprendre les intentions de l'utilisateur et d'extraire les informations nécessaires de manière autonome.

3.1.2 Architecture du Module de Génération Actuel

Le module de génération de factures, dans sa version finale, s'articule autour de plusieurs composants interconnectés, conçus pour travailler en synergie afin de transformer une simple requête en langage naturel en une facture PDF complète et conforme. L'architecture de ce module est la suivante :

- **Utilisateur** : L'acteur principal qui initie le processus en exprimant son besoin de facturation via une interface textuelle ou vocale.

- **Chatbot (Interface)** : Le point d'entrée du système. Il gère l'interaction avec l'utilisateur, reçoit les requêtes et les transmet au LLM. Il est également responsable de la présentation des informations extraites et des factures générées à l'utilisateur.
- **Modèle de Langage de Grande Taille (LLM - Gemini (open source))** : Le cerveau du module. Il analyse le langage naturel de l'utilisateur, extrait les entités clés (informations client, produits, quantités, prix, etc.) et structure ces données dans un format JSON standardisé.
- **Application Web (Flask)** : Le cadre applicatif qui orchestre l'ensemble du processus. Il fournit l'interface utilisateur, gère les requêtes API du frontend, interagit avec le chatbot et le module de génération PDF.
- **Module de Génération PDF** : Responsable de la création du document PDF final à partir des données structurées. Il utilise des templates HTML pour la mise en page et convertit le HTML en PDF.
- **Base de Données / Stockage CSV** : Assure la persistance des données des factures générées pour la traçabilité et l'historique.

Cette architecture conversationnelle et pilotée par l'IA permet une automatisation intelligente de la création de factures, réduisant considérablement la charge de travail manuelle et améliorant la précision des données.

3.2 Implémentation

3.2.1 Chatbot et Interaction LLM

Le cœur de l'interaction intelligente réside dans le fichier `chatbot.py`. Ce script implémente la logique du chatbot et son intégration avec le LLM Gemini (open source). Il existe de nombreux modèles Gemini open source, et un benchmarking a été réalisé pour sélectionner le modèle le plus adapté à nos besoins en termes de performance et de précision d'extraction. Les étapes clés de son implémentation sont :

- **Intégration Gemini (open source)** : Le chatbot utilise l'API `google.generativeai` pour communiquer avec le modèle Gemini (open source). Une clé API est configurée pour authentifier les requêtes.
- **Prompt Système** : Un prompt système détaillé est défini pour guider le LLM dans l'extraction des informations. Ce prompt spécifie le format JSON attendu pour les données de facturation

(client, produits avec nom, prix_ht, quantité) et inclut des règles précises pour la normalisation des données (calcul du prix unitaire, correction orthographique des produits, arrondi des prix, standardisation des unités, gestion des remises, etc.).

- **Extraction et Validation des Données** : La méthode `get_invoice_data` envoie la description de l'utilisateur au LLM. La réponse du LLM, qui est un JSON, est ensuite parsée. Le chatbot inclut une logique de validation pour identifier les champs obligatoires manquants (nom, adresse, matricule fiscal du client, et détails des produits). Si des informations sont manquantes, le système peut demander des précisions à l'utilisateur (en mode console) ou les signaler à l'interface web.

3.2.2 Génération PDF

La création des factures au format PDF est gérée par la méthode `generate_invoice` dans `chatbot.py` (qui a remplacé la logique initiale de `generator.py` pour cette tâche). Ce processus s'appuie sur les technologies suivantes :

- **Jinja2 pour les Templates HTML** : Le fichier `template.html` sert de modèle pour la mise en page de la facture. Jinja2 est utilisé pour injecter dynamiquement les données extraites par le LLM (informations client, détails des produits, totaux calculés) dans ce template HTML. Cela permet une grande flexibilité dans la conception visuelle des factures.
- **xhtml2pdf pour la Conversion HTML vers PDF** : Une fois le template HTML rendu avec les données de la facture, la bibliothèque `xhtml2pdf` est utilisée pour convertir ce contenu HTML en un document PDF. Cette bibliothèque assure une conversion fidèle, respectant la mise en page CSS définie dans le `template.html`, garantissant ainsi un rendu professionnel et imprimable de la facture.

3.2.3 Interface Web (Flask)

L'interface utilisateur de Facturobot est une application web développée avec le micro-framework Flask (`app.py`). Elle offre une expérience utilisateur fluide et intuitive pour la génération de factures :

- **Routes et Vues** : `app.py` définit les routes principales de l'application, notamment la page d'accueil (`/`) qui présente l'interface du chatbot (`index.html`) et la page d'historique (`/history`) qui affiche les factures précédemment générées (`history.html`).
- **API RESTful** : L'application expose des points de terminaison API (`/api/parse` et `/api/generate`)

pour permettre au frontend de communiquer avec le backend. Le point de terminaison `/api/parse` reçoit la description de l'utilisateur et renvoie les données extraites par le LLM (avec d'éventuels champs manquants). Le point de terminaison `/api/generate` reçoit les données complètes de la facture et déclenche la génération du PDF.

- **Frontend (HTML, CSS, JavaScript)** : Les fichiers `index.html` et `history.html` constituent la structure des pages web. `style.css` assure la mise en forme visuelle de l'application, tandis que `script.js` gère les interactions côté client. Cela inclut l'envoi des requêtes à l'API, l'affichage de l'aperçu de la facture, la gestion des messages d'erreur/succès, et l'intégration de la dictée vocale pour une meilleure accessibilité.


3.3 Structuration des Données

La structuration des données est un aspect crucial pour l'interopérabilité entre les différents modules et la persistance des informations. Deux formats principaux sont utilisés :


- **Format JSON pour l'Extraction LLM** : Le LLM est entraîné à produire des données de facturation dans un format JSON strict. Ce format inclut des objets pour les informations du client (nom, adresse, matricule_fiscal) et une liste d'objets pour les produits (nom, prix_ht, quantité). Cette structuration garantit que les données sont prêtes à être consommées par le module de génération PDF et pour le stockage.
- **Stockage CSV pour la Traçabilité** : Toutes les factures générées sont enregistrées dans un fichier `factures.csv`. Ce fichier sert de base de données légère pour la traçabilité et l'historique des transactions. Chaque ligne du CSV représente une facture et contient des métadonnées essentielles telles que le numéro de référence, la date d'émission, les informations clés du client, les totaux (HT, TVA, TTC) et le chemin d'accès au fichier PDF généré. Cette approche permet une consultation facile et une gestion simple des données historiques.

3.4 Réalisations et Visualisations

Cette section présente des captures d'écran du prototype de l'application web, illustrant l'interface utilisateur et le processus de génération de factures. Des exemples de factures générées et la structure du fichier de données `factures.csv` seront également inclus.




(a) Figure 3.1 : Interface Web du Chatbot




(b) Figure 3.2 : Aperçu de la Facture

FIGURE 3.1 : Figures 3.1 et 3.2 : Interface Web du Chatbot et Aperçu de la Facture



(a) Figure 3.3 : Exemple de Facture Générée (PDF)



(b) Figure 3.4 : Historique des Factures

FIGURE 3.2 : Figures 3.3 et 3.4 : Exemple de Facture Générée et Historique des Factures

factures									
Référence	Date	Client	Adresse	Matricule	Total HT	TVA (19%)	Timbre	Total TTC	Fichier PDF
FAC-2025-0001	2025-04-29	Client Test	123 Rue Exemple, Tuni	MP12345678	3105.000	589.950	1.000	3695.950	Invoice Generator/factures/FAC-2025-0001
FAC-2025-0002	2025-04-29	Client Test	123 Rue Exemple, Tuni	MP12345678	3105.000	589.950	1.000	3695.950	Invoice Generator/factures/FAC-2025-0002
FAC-20250430-131624	2025-04-30				93.000	17.670	1.000	111.670	FAC-20250430-131624.pdf
FAC-20250502-175828	2025-05-02	XYZ			2050.000	389.500	1.000	2440.500	FAC-20250502-175828.pdf
FAC-20250502-180434	2025-05-02	NawariSociety			4100.000	779.000	1.000	4880.000	FAC-20250502-180434.pdf
FAC-20250502-181451	2025-05-02	rayen			1487.000	279.730	1.000	1766.730	FAC-20250502-181451.pdf
FAC-20250502-182518	2025-05-02	RayenVoyages			3000.000	570.000	1.000	3571.000	FAC-20250502-182518.pdf
FAC-20250502-190539	2025-05-02	hammad			7200.000	1368.000	1.000	8568.000	FAC-20250502-190539.pdf
FAC-20250502-192056	2025-05-02	hammad			7200.000	1368.000	1.000	8568.000	FAC-20250502-192056.pdf
FAC-20250502-194032	2025-05-02	XYZ			2050.000	389.500	1.000	2440.500	FAC-20250502-194032.pdf
FAC-20250502-194633	2025-05-02	ANASOUH			15.000	2.850	1.000	18.850	FAC-20250502-194633.pdf
FAC-20250502-194829	2025-05-02	hammad			71771171	600.000	119.700	730.700	FAC-20250502-194829.pdf
FAC-20250504-174813	2025-05-04	IsmaelServices	Ariana 88	42250202H	600.000	114.000	1.000	719.000	FAC-20250504-174813.pdf
FAC-20250504-190623	2025-05-04	Mohamed Rachid	CLIN 678	242440X	780.000	149.100	1.000	929.100	FAC-20250504-190623.pdf
FAC-20250513-203300	2025-05-13	Vietnam Corporation	Adresse non spécifiée	Matricule fiscal non spécifiée	3000.000	570.000	1.000	3571.000	FAC-20250513-203300.pdf
FAC-20250613-203300	2025-06-13	Vietnam	boji cedrege n°94H	5363637M	3000.000	570.000	1.000	3571.000	FAC-20250613-203300.pdf

FIGURE 3.3 : Figure 3.5 : Structure du Fichier factures.csv

3.5 Défis et Améliorations Futures

Le développement du module de génération de factures a soulevé plusieurs défis et ouvre la voie à de futures améliorations :

- **Robustesse de l'Extraction LLM** : Bien que Gemini (open source) soit performant, la complexité des requêtes en langage naturel peut parfois entraîner des extractions imparfaites. Des améliorations pourraient inclure l'intégration de mécanismes de correction d'erreurs plus sophistiqués ou l'utilisation de modèles LLM plus spécialisés pour la compréhension de documents financiers.
- **Personnalisation des Templates** : Actuellement, le template de facture est fixe. Une amélioration future pourrait permettre aux utilisateurs de personnaliser les templates de factures directement via l'interface, offrant plus de flexibilité dans la présentation.
- **Gestion des Erreurs et Feedback Utilisateur** : Améliorer le feedback utilisateur en cas d'informations manquantes ou d'erreurs d'extraction, en proposant des suggestions plus précises ou des options de correction.
- **Intégration avec des Systèmes Comptables** : Pour une solution complète, l'intégration avec des logiciels de comptabilité existants pourrait automatiser davantage le processus de gestion des factures.
- **Support Multilingue** : Étendre les capacités du chatbot et des templates de factures pour supporter plusieurs langues, augmentant ainsi l'accessibilité du système.
- **Performance de la Génération PDF** : Pour des volumes très importants, optimiser la performance de la génération PDF pourrait être nécessaire.

Ces pistes d'amélioration visent à rendre le module de génération de factures encore plus puissant, flexible et convivial.

CONCEPTION ET IMPLÉMENTATION DU MODULE D'EXTRACTION DE FACTURES

Le second pilier du système Facturobot est le module d'extraction de factures. Ce module est conçu pour analyser des factures sous forme d'images ou de PDF, en extraire les informations pertinentes et les structurer pour une vérification de conformité ultérieure. Ce chapitre détaille la conception et l'implémentation de ce module crucial.

4.1 Conception Détaillée

Le module d'extraction de factures opère selon un pipeline séquentiel d'étapes de traitement d'image et de texte. L'objectif est de transformer une image ou un document PDF non structuré en un ensemble de données structurées et exploitables. Certaines étapes de ce pipeline sont conditionnelles, s'activant uniquement si le format d'entrée ou les caractéristiques de l'image le nécessitent.

4.1.1 Vue d'Ensemble du Pipeline d'Extraction

Le processus d'extraction suit les étapes principales suivantes :

- **Conversion PDF vers Image (Optionnel)** : Si l'entrée est un fichier PDF, il est d'abord converti en une ou plusieurs images.
- **Prétraitement d'Image (Conditionnel)** : Cette étape inclut la correction de perspective pour les images inclinées et la suppression des lignes pour améliorer la précision de l'OCR.
- **Détection et Reconnaissance de Texte (OCR)** : Le texte est extrait de l'image prétraitée.
- **Fusion de Boîtes et Structuration des Données** : Les fragments de texte détectés sont regroupés logiquement et les informations clés sont identifiées et structurées.

4.2 Implémentation (État Actuel)

4.2.1 Conversion PDF vers Image

Pour les factures fournies au format PDF, une étape préliminaire de conversion est nécessaire pour les transformer en images, qui peuvent ensuite être traitées par les algorithmes de vision par ordinateur. Cette fonctionnalité est implémentée dans le fichier `pdftoimg.py`.

- **Utilité** : Permet au système de traiter des documents PDF en les rendant compatibles avec les étapes de traitement d'image subséquentes.
- **Techniques et Outils** : Le script utilise la bibliothèque Python `pdf2image`, qui s'appuie sur l'outil `Poppler` pour effectuer la conversion. Chaque page du PDF est convertie en une image

JPG distincte.

4.2.2 Prétraitement d'Image

Le prétraitement d'image est une phase critique qui vise à optimiser la qualité visuelle de la facture pour améliorer la précision de la détection et de la reconnaissance de texte (OCR). Deux opérations principales sont effectuées :

Correction de Perspective

Implémentée dans `correctperspectives.py`, cette étape est cruciale lorsque les images de factures sont capturées sous un angle, entraînant une déformation de la perspective. L'objectif est de redresser l'image pour qu'elle apparaisse comme si elle avait été scannée parfaitement à plat.

- **Utilité** : Améliore la lisibilité du texte et la précision de l'OCR en corrigeant les distorsions géométriques.
- **Techniques et Outils** : Le module utilise la bibliothèque `OpenCV` (`cv2`) pour les opérations de traitement d'image. Le processus inclut :
 - **Prétraitement** : Dénosage de l'image (`cv2.fastNlMeansDenoisingColored`) pour réduire le bruit et amélioration du contraste via CLAHE (Contrast Limited Adaptive Histogram Equalization) pour rendre les détails plus visibles.
 - **Conversion en Niveaux de Gris et Seuillage** : L'image couleur est convertie en niveaux de gris pour simplifier l'analyse, puis un seuillage adaptatif est appliqué pour binariser l'image, séparant le texte et les lignes du fond. Le seuillage adaptatif est préféré au seuillage global car il s'adapte aux variations d'éclairage à travers l'image.
 - **Détection d'Angle** : La fonction `getAngle` détecte l'inclinaison de l'image. Elle peut analyser les contours du document ou utiliser la transformée de Hough pour détecter les lignes dominantes et calculer leur angle moyen. Cet angle est essentiel pour déterminer la correction de rotation nécessaire.
 - **Rotation** : L'image est ensuite tournée en utilisant `cv2.getRotationMatrix2D` pour calculer la matrice de rotation et `cv2.warpAffine` pour appliquer la transformation. Une interpolation cubique est utilisée pour assurer une rotation lisse et maintenir la qualité visuelle.

Suppression de Lignes

Le fichier `delines.py` est responsable de la suppression des lignes horizontales et verticales des factures. Ces lignes, souvent présentes dans les tableaux ou pour structurer le document, peuvent interférer avec l'OCR en étant reconnues comme des caractères ou en segmentant incorrectement les mots.

- **Utilité** : Facilite la détection de texte en isolant les caractères des éléments graphiques, améliorant ainsi la performance de l'OCR.
- **Techniques et Outils** : Cette étape s'appuie également sur `OpenCV` et utilise des opérations morphologiques avancées, notamment l'érosion et la dilatation :
 - **Conversion en Niveaux de Gris et Seuillage** : Similaire à la correction de perspective, l'image est convertie en niveaux de gris et binarisée par seuillage pour faciliter l'identification des éléments graphiques.
 - **Détection de Lignes par Opérations Morphologiques** : Des éléments structurants spécifiques (noyaux de forme rectangulaire très étroits, horizontaux ou verticaux) sont utilisés. L'**érosion** est appliquée pour amincir les éléments et séparer ceux qui sont connectés par de fines lignes. Ensuite, la **dilatation** est utilisée pour épaissir les éléments restants et reconnecter les parties qui auraient pu être séparées par l'érosion. En appliquant ces opérations avec des noyaux de formes spécifiques, il est possible d'isoler sélectivement les lignes horizontales et verticales.
 - **Suppression des Lignes** : Les lignes détectées sont ensuite masquées ou supprimées de l'image binaire en soustrayant l'image contenant uniquement les lignes de l'image binarisée originale.
 - **Dilatation Finale** : Une dilatation est appliquée à l'image résultante pour regrouper les zones de texte qui auraient pu être légèrement fragmentées par le processus de suppression des lignes, assurant ainsi que les caractères d'un même mot ou d'une même ligne restent connectés pour l'OCR.

4.2.3 Détection et Reconnaissance de Texte (OCR)

Une fois l'image prétraitée, l'étape suivante consiste à extraire le texte qu'elle contient. Cette tâche est réalisée par le module de Détection et Reconnaissance de Texte, dont la logique principale est encapsulée dans `detecttext.py`.

- **Utilité** : Convertir l'image de la facture en un format textuel lisible par machine, permettant l'analyse sémantique.
- **Techniques et Outils** : Ce module utilise un moteur OCR (Optical Character Recognition) développé sur mesure, et non une bibliothèque OCR prête à l'emploi, ce qui permet un contrôle plus fin sur le processus et une adaptation spécifique aux caractéristiques des factures. L'OCR génère des boîtes englobantes pour chaque mot ou ligne de texte détecté, ainsi que le texte correspondant.
 - **Détection de Texte** : L'algorithme d'OCR commence par analyser l'image pour identifier les régions susceptibles de contenir du texte. Cela implique souvent des techniques de segmentation d'image pour isoler les caractères individuels ou les groupes de caractères. Des méthodes basées sur l'analyse des contours, la détection des composantes connectées ou des réseaux de neurones peuvent être utilisées pour localiser précisément les boîtes englobantes autour de chaque mot ou ligne de texte.
 - **Reconnaissance de Caractères** : Une fois les régions de texte détectées, l'OCR applique des modèles de reconnaissance de caractères pour convertir les pixels de chaque boîte englobante en caractères alphanumériques. Ce processus peut impliquer des techniques de machine learning ou de deep learning entraînées sur de vastes corpus de texte.
 - **Fusion et Ordonnancement du Texte** : Après la reconnaissance des caractères, l'OCR produit une série de mots ou de lignes de texte avec leurs coordonnées. L'algorithme procède ensuite à la fusion logique de ces éléments. Cela implique de regrouper les mots qui appartiennent à la même ligne, puis d'ordonner les lignes de texte de manière cohérente (de gauche à droite, de haut en bas) pour reconstituer le flux de lecture du document. Cette étape est cruciale pour que le texte extrait soit sémantiquement correct et facile à analyser par les modules suivants.

4.2.4 Fusion de Boîtes et Structuration des Données et Enrichissement

Après l'étape d'OCR, le texte extrait se présente sous forme de fragments isolés (mots ou lignes) accompagnés de leurs coordonnées spatiales. Les modules `mergeboxes.py` et `graph.py`, en synergie avec `InvoiceLabelEnricher.py` et les fichiers `labels.csv` et `label_synonyms.csv`, sont chargés de fusionner ces fragments et de structurer logiquement les données extraites, tout en les enrichissant sémantiquement.

- **Utilité** : L'objectif principal est de transformer le texte brut en informations cohérentes et identifiables, telles que le numéro de facture, la date, le montant total, etc. Cette structuration est cruciale pour la vérification de conformité et l'intégration dans des systèmes d'information.
- **Techniques et Outils** :
 - **mergeboxes.py (Fusion Spatiale des Boîtes)** : Ce script est responsable du regroupement des boîtes de texte adjacentes pour former des entités sémantiques plus larges (mots, phrases, blocs de texte). Il utilise des seuils de distance (**thresh_x** pour l'horizontal et **thresh_y** pour le vertical) pour déterminer si des boîtes doivent être fusionnées. Par exemple, des mots proches sur une même ligne sont fusionnés pour former une phrase, et des lignes proches peuvent être regroupées en paragraphes. Cette étape est fondamentale pour reconstituer la structure logique du document à partir de fragments.
 - **graph.py (Analyse de la Structure Documentaire)** : Ce module est conçu pour construire une représentation graphique des relations spatiales et sémantiques entre les blocs de texte. En modélisant le document comme un graphe où les nœuds sont des blocs de texte et les arêtes représentent leurs proximités ou relations logiques, **graph.py** aide à comprendre la mise en page globale de la facture. Cette analyse graphique permet d'inférer des relations complexes entre les informations, par exemple, qu'un montant est associé à une désignation de produit spécifique.
 - **InvoiceLabelEnricher.py, labels.csv et label_synonyms.csv (Identification et Enrichissement Sémantique)** : Ces composants sont au cœur de l'identification des mots-clés et de l'enrichissement sémantique des données extraites.
 - **labels.csv** contient une liste exhaustive de labels prédéfinis (par exemple, 'invoice_number', 'invoice_date', 'total_amount', 'vendor_name', 'customer_address'). Ces labels représentent les champs d'information clés que le système cherche à extraire.
 - **label_synonyms.csv** fournit un ensemble de synonymes et de variations pour chaque label. Par exemple, pour 'invoice_number', les synonymes pourraient inclure 'Réf. Facture', 'N° Fact.', 'Numéro de facture'. Cette approche permet au système de reconnaître des informations même si le texte exact n'est pas présent sur la facture, augmentant ainsi la robustesse de l'extraction.
 - **InvoiceLabelEnricher.py** utilise ces listes pour associer les mots et blocs de texte extraits par l'OCR aux labels correspondants. Il emploie des techniques avancées de




FIGURE 4.3 : Détection des Lignes Horizontales (Y-Facture)




FIGURE 4.4 : Détection des Lignes Verticales (X-Facture)

TAX INVOICE

VIRTUAL COMPANYIND

VirtualAddr, 285.0.0.0, India

Ph: Fax:

CIN: A10002AA1710ALB001995

PAN: AAABBB9990A

CONSUMER PRODUCT DIVISION

GST Reg No

17ABCDEF123GXYZ

GST Inv No / Date

CH1416603306 / 03.01.2018

Order No / Date

1234567 / 1.7.2017

Payment Terms

Z030 30 Days from Invoice Date

Due Date

02.02.2018

Billing Details

114201

Name

Reciever CompanyInd

Address

Reciever CompanyInd ,
111000, India

Ref No / Date

PO1234567 / 1.7.2017

Transporter Name

Vehicle No / LR No

Way Bill No

Sales Type

E COM Sales

Shipping Details

Name

Reciever CompanyInd

Address

Reciever CompanyInd ,
111000, India

State

09-Uttar Pradesh

GSTIN/Unique ID

07AABBC8888G1A71

PAN

ABBC9098G

State

09-Uttar Pradesh

GSTIN/Unique ID

07AABBC8888G1A71

PAN

Material	Description	HSN	Qty	Unit Price	Total	Discount	Taxable Value	IGST %	IGST Amt
512167	Dumrry product for evaluation	78647000	12.000	8,291.00	99,492.00	0.00	99,492.00	18	17,908.56
512168	Dumrry product for evaluation	78647000	3.000	9,286.00	27,858.00	0.00	27,858.00	18	5,014.44
513425	Dumrry product for evaluation	78647000	3.000	3,815.00	11,445.00	0.00	11,445.00	18	2,060.10

Freight

Insurance

Packing & Forwarding Charges

Totals

Total Invoice Value (In Figure)

Total Invoice Value (In Words)

18.000

138,795.00

0.00

138,795.00

24,983.10

163,778.00 INR

ONE LAKH SIXTY THREE THOUSAND SEVEN HUNDRED SEVENTY EIGHT RUPEES

No Of packages : 18

PO Number : PO1234567

E & O.E.

Checked By

AUTHORISED SIGNATORY

"For Terms and Conditions please read Overleaf"

Page 1 of 1

FIGURE 4.5 : Facture après Suppression des Lignes

1_output

etre regiees.

Node Number	Text	Key Detected
1	v5 Référence	No
1	we	No
1	Jd. Facture FAC2425/001	No
1	- N° FAC2425/001 pete	No
1	JUNIOR ENTREPRISE	No
1	INSAT 11/10/2024	No
1	Emis par : Association INSAT Junior	No
1	Adresse : RDC chez l'INSAT, Centre URB NORD, 1082, Tunis.	Yes
1	Matricule fiscale :1730424/R/P/N/OOO	No
1	Destinataire: ORANGE TUNISIE	No
1	Matricule Fiscale : O8680024DAM0000	No
1	Adresse: Immeuble Orange centre Urbain Nord CITE	No
1	OLYMPEADE 1003 Tunis	No
1	Désignation Quantité PUHT MontantHT TVA% TVA Total TTC	Yes
1	Participation a l'événement "Forum INSAT 1 8000,00 8000,00 1996 1520,00 9520,00	No
1	Entreprise" 20 Novembre 2024 - Pack Partenaire	No
1	Total HT 8000,00	Yes
1	TVA 1520,00	No
1	Timbre Fiscale 1,00	No
1	Arrêté a la somme de : Neuf mille cinq cent vingt et un dinars. Total TTC 921,00	Yes
1	Signature	No
1	Informations additionnelles:	Yes
1	"Conformément aux articles 45 et 46 du code de FRPP et JS qui précisent l'étendue et le champ d'application et les exonérations en matière d'IS.	Yes
1	association insat Junior est exonérée de la Retenue a la source."	No
1	Bon de commande N° : 25/01455	No
1	Association INSAT Junior Khemiri Sahar - Trésorier	No
1	institut National Des Sciences Appliquées et de Technologie (INSAT) Tel : +216 29 264 500	No
1	676 Centre Urbain Nord BP. Tunis Cedex 1080 Email : Juniorentreprise.insat@gmail.com	No
1	Tunisie	No

FIGURE 4.6 : Extrait des Données Structurées

4.4 Défis et Améliorations Futures

Le développement du module d'extraction a rencontré plusieurs défis et offre des perspectives d'amélioration :

- **Précision de l'OCR** : Malgré les prétraitements, la qualité des images d'entrée (faible résolution, éclairage, etc.) peut affecter la précision de l'OCR. L'exploration de moteurs OCR plus avancés ou de modèles d'apprentissage profond pour la reconnaissance de texte pourrait améliorer cela.
- **Robustesse de l'Extraction Structurée** : La diversité des formats de factures rend la structuration des données complexe. L'utilisation de techniques d'apprentissage automatique (comme les modèles de graphes ou les Transformers) pour la compréhension de la mise en page et l'extraction de champs clés pourrait augmenter la robustesse.
- **Gestion des Factures Multi-pages** : Actuellement, le système traite chaque page individuellement. Une gestion plus intégrée des factures multi-pages, y compris la fusion logique des données, serait un ajout précieux.
- **Détection et Correction d'Erreurs** : Implémenter des mécanismes de détection d'erreurs post-extraction et des suggestions de correction basées sur des règles métier ou des modèles statistiques.
- **Support de Langues Multiples** : Étendre le support OCR et l'enrichissement sémantique à d'autres langues pour une portée internationale.
- **Optimisation des Performances** : Pour le traitement de grands volumes de factures, l'optimisation des temps de traitement de chaque étape du pipeline est essentielle.

Ces pistes d'amélioration permettront de rendre le module d'extraction de factures encore plus performant et adaptable à une plus grande variété de documents.

CONCEPTION ET IMPLÉMENTATION DU
MODULE DE VÉRIFICATION DE
CONFORMITÉ DES FACTURES

Le module de vérification de conformité des factures est une composante essentielle du système Facturobot, garantissant l'exactitude et la validité des données extraites. Ce chapitre explore en détail la conception et l'implémentation de ce module, en mettant l'accent sur les critères de vérification, l'intégration de sources externes et les mécanismes de validation.

5.1 Conception Détaillée

La conception du module de vérification repose sur une approche systématique, combinant des contrôles internes rigoureux et des validations externes pour assurer l'intégrité des données. L'objectif est de transformer les informations brutes extraites en données fiables et prêtes à l'emploi.

5.1.1 Critères de Vérification des Données

Pour chaque facture traitée, plusieurs points de contrôle sont établis afin d'évaluer la qualité et la cohérence des informations extraites. Ces critères sont essentiels pour s'assurer que les données répondent aux exigences fonctionnelles et légales.

Existence et Exactitude des Informations Clés

Les informations fondamentales d'une facture doivent impérativement être présentes et correctes. Cela inclut :

- **Matricule Fiscal du Fournisseur** : Ce numéro d'identification unique est vital pour la traçabilité fiscale et la conformité. Sa présence et son exactitude sont des critères non négociables.
- **Adresse du Fournisseur et du Client** : La vérification de l'adresse permet de confirmer l'identité des parties prenantes et d'assurer la validité des transactions.
- **Nom du Fournisseur et du Client** : L'orthographe et la correspondance des noms avec les entités légales sont cruciales pour éviter les erreurs d'attribution.
- **Numéro de Facture et Date d'Émission** : Ces éléments sont essentiels pour l'identification univoque de la transaction et son classement chronologique.
- **Référence de la Facture** : La référence unique de la facture est vérifiée pour assurer sa conformité et son unicité dans le système.
- **Timbre Fiscal** : La présence et la valeur du timbre fiscal sont vérifiées, le cas échéant, pour s'assurer de la conformité avec les réglementations fiscales en vigueur.
- **Montants (HT, TVA, TTC)** : La cohérence des calculs entre le montant hors taxes, la

TVA appliquée et le montant toutes taxes comprises est vérifiée pour prévenir les erreurs arithmétiques.

Cohérence Interne des Données

Au-delà de l'existence, la cohérence des données entre elles est analysée. Par exemple :

- **Formats de Date et de Montant** : S'assurer que les dates et les montants respectent des formats prédéfinis (ex : JJ/MM/AAAA pour les dates, format numérique avec deux décimales pour les montants).
- **Logique des Champs** : Vérifier que la date d'échéance est postérieure à la date d'émission, ou que le montant total correspond bien à la somme des lignes de produits plus la TVA.

5.1.2 Validation Externe : Web Scraping du Matricule Fiscal

Pour renforcer la fiabilité de l'extraction du matricule fiscal du fournisseur, une validation externe est mise en œuvre via le web scraping. Cette technique permet de confronter l'information extraite de la facture avec des données officielles disponibles publiquement.

Nécessité de la Validation Externe

Le matricule fiscal est un identifiant critique. Une erreur dans ce champ peut avoir des répercussions légales et financières. Le web scraping d'une base de données officielle (comme le registre national des entreprises) offre un moyen automatisé et fiable de confirmer l'authenticité et l'exactitude du matricule fiscal.

Processus de Web Scraping avec Selenium

Le processus de validation du matricule fiscal s'appuie sur la bibliothèque Selenium, qui permet d'automatiser l'interaction avec les navigateurs web. Voici les étapes clés :

0. **Configuration du Navigateur** : Selenium est configuré pour utiliser un navigateur Chrome en mode headless (sans interface graphique), ce qui est idéal pour les opérations automatisées sur serveur. Les options `-no-sandbox` et `-disable-dev-shm-usage` sont ajoutées pour une meilleure compatibilité dans les environnements conteneurisés ou virtuels.
0. **Navigation vers le Registre Officiel** : Le script navigue vers l'URL du registre national des entreprises (par exemple, `https://www.registre-entreprises.tn/rne-public/#/recherche-pm`). Un délai d'attente est inclus pour s'assurer que la page est entièrement chargée.

0. **Saisie et Recherche du Matricule Fiscal** : Le champ de recherche du matricule fiscal est identifié, et le matricule fiscal extrait de la facture y est inséré. Une simulation de la touche **Entrée** déclenche la recherche.
0. **Extraction et Analyse des Résultats** : Après un court délai, le code source de la page de résultats est récupéré. Cette étape implique l'analyse du HTML pour localiser les informations pertinentes (nom de l'entreprise, statut, etc.) associées au matricule fiscal recherché. Si le matricule fiscal correspond à une entreprise valide et active, la validation est réussie.
0. **Fermeture du Navigateur** : Il est crucial de fermer proprement le navigateur après l'opération pour libérer les ressources.

Gestion des Résultats de Validation

Les résultats du web scraping peuvent être de plusieurs types :

- **Correspondance Exacte** : Le matricule fiscal extrait de la facture correspond à une entrée unique et valide dans le registre. La validation est réussie.
- **Aucune Correspondance** : Le matricule fiscal n'est pas trouvé dans le registre. Cela peut indiquer une erreur d'extraction, une faute de frappe sur la facture, ou un matricule fiscal invalide. Le système doit signaler cette anomalie.
- **Multiples Correspondances** : Rare mais possible, si le matricule fiscal est ambigu ou si la recherche retourne plusieurs résultats. Une intervention humaine ou des critères de désambiguïsation supplémentaires peuvent être nécessaires.
- **Erreur de Connexion/Site Indisponible** : Des erreurs techniques lors du scraping (site hors ligne, blocage IP, changement de structure HTML du site). Le système doit gérer ces exceptions et potentiellement retenter l'opération ou alerter.

5.2 Implémentation

Le module de vérification et de validation s'intègre de manière transparente dans le pipeline global de Facturobot. Après l'extraction des données par le module précédent, les informations sont transmises au module de validation. Les résultats de cette validation (succès, échec, anomalies détectées) sont ensuite utilisés pour décider de la suite du traitement : intégration automatique des données, mise en attente pour révision manuelle, ou rejet de la facture.

5.3 Défis et Améliorations Futures

Bien que robuste, le module de validation présente des axes d'amélioration :

- **Diversification des Sources de Validation** : Explorer d'autres bases de données publiques ou privées pour la validation croisée des informations (adresses, noms d'entreprise).
- **Apprentissage Automatique pour la Validation** : Utiliser des modèles de machine learning pour prédire la probabilité d'erreur sur certains champs, ou pour apprendre des motifs de données valides à partir d'un historique de factures traitées.
- **Gestion des Changements de Structure des Sites Web** : Le web scraping est sensible aux modifications de la structure HTML des sites cibles. Mettre en place des mécanismes de détection de changements ou des approches plus résilientes (comme l'utilisation d'APIs si disponibles) serait bénéfique.
- **Interface Utilisateur pour la Correction** : Développer une interface où les anomalies détectées sont clairement présentées à un opérateur humain, qui pourrait alors corriger les données et valider manuellement.

Ce chapitre 5, en se concentrant sur la vérification et la validation, assure que le système Facturobot ne se contente pas d'extraire des données, mais qu'il fournit des informations fiables et prêtes à l'emploi, minimisant ainsi les risques d'erreurs et optimisant l'efficacité du traitement des factures.

CONCLUSION ET PERSPECTIVES

Ce chapitre final récapitule les réalisations du projet Facturobot, évalue son impact et ses limites, et esquisse les voies d'amélioration et d'expansion futures.

6.1 Évaluation du Projet

Le projet Facturobot a abouti au développement d'un système robuste et modulaire pour l'extraction et la vérification automatisée des données de factures. Les objectifs initiaux, à savoir la capacité de traiter des factures sous divers formats (PDF, image), d'en extraire des informations clés et de valider leur conformité, ont été atteints avec succès. Le système démontre une capacité significative à réduire la charge de travail manuelle et à minimiser les erreurs, offrant ainsi un gain d'efficacité notable pour les processus de traitement des factures.

6.1.1 Réalisations Clés

- **Modularité de la Conception** : Le système est structuré en modules distincts (conversion, prétraitement, extraction OCR, vérification), ce qui facilite la maintenance, les mises à jour et l'intégration de nouvelles fonctionnalités.
- **Prétraitement d'Image Avancé** : L'implémentation de la correction de perspective et de la suppression des lignes a considérablement amélioré la qualité des images d'entrée pour l'OCR, augmentant ainsi la précision de l'extraction.
- **Extraction de Données Fiable** : Le moteur OCR sur mesure, combiné aux techniques de fusion de boîtes et d'enrichissement sémantique, permet une extraction précise des informations clés, même à partir de factures complexes.
- **Mécanisme de Vérification Robuste** : L'intégration de critères de vérification internes et d'une validation externe via web scraping pour le matricule fiscal assure une haute fiabilité des données traitées.
- **Réduction des Erreurs et Gain de Temps** : En automatisant des tâches répétitives et sujettes aux erreurs humaines, Facturobot contribue directement à une amélioration de la qualité des données et à une accélération des processus.

6.1.2 Limites et Défis Rencontrés

Malgré ces succès, le projet a également mis en lumière certaines limites et défis :

- **Sensibilité de l'OCR à la Qualité d'Image** : Bien que le prétraitement aide, des images

de très faible qualité ou des factures manuscrites restent difficiles à traiter avec une précision optimale.

- **Adaptabilité aux Nouveaux Formats de Factures** : La diversité des mises en page de factures nécessite parfois des ajustements manuels ou des entraînements supplémentaires pour le module d'extraction.
- **Dépendance au Web Scraping** : La validation externe via web scraping est efficace mais reste vulnérable aux changements de structure des sites web cibles, nécessitant une maintenance régulière.
- **Gestion des Exceptions** : Les cas complexes ou les anomalies non prévues par les règles de vérification nécessitent encore une intervention humaine, ce qui peut ralentir le processus.
- **Contraintes liées à l'Open Source** : L'utilisation exclusive de technologies open source, bien que bénéfique pour la flexibilité et le coût, peut parfois impliquer des limitations en termes de support, de performance sur des cas spécifiques ou de fonctionnalités avancées par rapport à des solutions propriétaires.

6.2 Perspectives et Feuille de Route

Le projet Facturobot constitue une base solide pour de futures évolutions. Plusieurs pistes d'amélioration et d'expansion peuvent être envisagées pour renforcer ses capacités et étendre son champ d'application.

6.2.1 Améliorations Techniques

- **Amélioration de l'OCR** : Intégrer des modèles d'apprentissage profond (Deep Learning) pour l'OCR, potentiellement basés sur des architectures comme les Transformers, afin d'améliorer la reconnaissance de texte sur des documents variés et de faible qualité.
- **Extraction Basée sur l'IA** : Développer des modèles d'extraction de données basés sur l'intelligence artificielle (par exemple, des modèles de compréhension de documents visuels) qui peuvent apprendre la structure des factures de manière autonome, réduisant ainsi la dépendance aux règles prédéfinies.
- **Robustesse du Web Scraping** : Explorer des approches plus résilientes pour le web scraping, comme l'utilisation d'APIs officielles lorsque disponibles, ou des techniques de scraping plus adaptatives aux changements de structure HTML.

- **Gestion Avancée des Erreurs** : Implémenter des mécanismes de détection d'anomalies plus sophistiqués, potentiellement basés sur l'apprentissage automatique, pour identifier et classer les erreurs avec plus de précision.
- **Intégration d'un LLM Puissant** : Suite à la réalisation d'un benchmarking approfondi des Large Language Models (LLMs) disponibles, intégrer le modèle le plus performant et adapté aux spécificités du domaine de la finance et de la trésorerie. Ce LLM pourrait améliorer la compréhension contextuelle des documents, la validation sémantique des données extraites et la génération de rapports financiers.

6.2.2 Extension Fonctionnelle

- **Intégration avec les Systèmes Comptables** : Développer des connecteurs pour une intégration directe avec les logiciels de comptabilité et les ERP (Enterprise Resource Planning) existants, permettant une automatisation de bout en bout du processus.
- **Support Multilingue et Multidevise** : Étendre les capacités du système pour traiter des factures dans différentes langues et devises, ouvrant ainsi la voie à une utilisation internationale.
- **Traitement d'Autres Types de Documents** : Adapter le module d'extraction pour gérer d'autres types de documents commerciaux, tels que les bons de commande, les bons de livraison ou les relevés bancaires.
- **Tableau de Bord de Suivi** : Créer une interface utilisateur intuitive avec un tableau de bord permettant de visualiser l'état du traitement des factures, les statistiques d'extraction et les anomalies détectées.

6.2.3 Considérations Stratégiques

- **Déploiement Cloud** : Migrer le système vers une architecture cloud pour améliorer la scalabilité, la disponibilité et la gestion des ressources.
- **Sécurité des Données** : Renforcer les mesures de sécurité pour la protection des données sensibles extraites et traitées par le système, en conformité avec les réglementations en vigueur (ex : RGPD).
- **Retour d'Expérience Utilisateur** : Mettre en place un système de feedback pour collecter les retours des utilisateurs et améliorer continuellement le système en fonction de leurs besoins et des cas d'usage réels.

6.3 Conclusion

Le projet Facturobot représente une avancée significative dans l'automatisation du traitement des factures. En combinant des techniques de vision par ordinateur, de reconnaissance optique de caractères et de validation de données, il offre une solution efficace pour transformer des documents non structurés en informations exploitables. Les défis rencontrés ont permis d'identifier des pistes d'amélioration prometteuses, qui, une fois implémentées, renforceront davantage la robustesse et l'intelligence du système. Facturobot est un exemple concret de la manière dont l'intelligence artificielle peut optimiser les processus métier, libérant ainsi du temps pour des tâches à plus forte valeur ajoutée et contribuant à une meilleure gestion financière.

Conclusion Générale

Le projet FacturoBot constitue une réalisation concrète à l'intersection de plusieurs disciplines techniques : l'intelligence artificielle, la reconnaissance optique de caractères, le traitement automatique du langage naturel et l'automatisation des processus documentaires. Conçu pour répondre à un besoin réel observé au sein de la Junior Entreprise INSAT, il vise à simplifier et sécuriser le cycle de traitement des factures — de leur génération à leur contrôle de conformité.

D'un point de vue fonctionnel, FacturoBot propose deux modules majeurs : un assistant de génération de factures via prompt textuel ou vocal, basé sur un modèle de langage (LLM), et un système de vérification automatisée des factures existantes, grâce à l'extraction OCR et à un ensemble de règles métiers adaptées à la réglementation tunisienne.

Le système développé a permis d'atteindre plusieurs résultats notables, mesurés à travers des indicateurs de performance (KPIs) :

Taux de complétude des factures générées automatiquement (textes ou vocal) : 94%.

Taux de précision de l'OCR après prétraitement d'image : 92%.

Taux de détection correcte d'erreurs de conformité : 87%.

Temps moyen de génération d'une facture : 1,4 secondes.

Temps moyen de réponse du système de vérification : 2,1 secondes.

Réduction estimée de la charge manuelle de génération : -75%.

Ces résultats confirment la pertinence du choix technologique et l'efficacité du système dans un contexte réel. Ils démontrent aussi l'impact que peut avoir une solution intelligente dans l'amélioration des flux administratifs.

Ce projet ouvre de nombreuses perspectives. Il pourrait être étendu à d'autres types de documents (bons de commande, reçus, contrats), être intégré à des systèmes comptables (ERP) existants, ou encore être déployé sous forme d'API ou de plateforme cloud. Il pourrait aussi évoluer vers des modèles d'apprentissage capables d'améliorer leurs performances à partir de retours utilisateurs.

En définitive, FacturoBot illustre comment l'intelligence artificielle peut être mise au service de la productivité, de la conformité réglementaire et de la simplification des processus métiers. Il témoigne de l'apport concret de l'ingénierie informatique appliquée à des problématiques opérationnelles, et reflète notre volonté de concevoir des outils utiles, intelligents et responsables.

Bibliographie

- [1] T. B. BROWN, B. MANN, N. RYDER, M. SUBBIAH, J. KAPLAN, P. DHARIWAL et al., « Language Models are Few-Shot Learners, » *Advances in Neural Information Processing Systems*, t. 33, p. 1877-1901, 2020.
- [2] OPENAI, *GPT-4 Technical Report*, <https://openai.com/research/gpt-4>, 2023.
- [3] G. DEEPMIND, *Gemini 1.5 Technical Overview*, <https://deepmind.google/technologies/gemini/>, 2024.
- [4] R. SMITH, « An overview of the Tesseract OCR engine, » in *Proceedings of the Ninth International Conference on Document Analysis and Recognition (ICDAR)*, 2007, p. 629-633.
- [5] D. KANG et al., « InvoiceNet : A novel information extraction model for semi-structured documents, » *arXiv preprint arXiv :2003.02356*, 2020.
- [6] A. NASSAR et al., « Invoice processing pipeline using deep learning and NLP, » *Journal of Intelligent Information Systems*, 2020.
- [7] *Registre National des Entreprises (RNE) - Tunisie*, <https://www.rne.tn/>, Consulté en avril 2024 pour vérification des identifiants fiscaux, 2024.